BIG DATA

LABDATA

Introdução ao Big Data

Tema da Aula: **Twitter REST API**

Prof.: **Dino Magri**

Data: **11 de Outubro de 2017**

Coordenação:

Prof. Dr. Adolpho Walter Pimazzi Canton

Profa. Dra. Alessandra de Ávila Montini

LABDATA

Coordenação:

Prof. Dr. Adolpho Walter Pimazzi Canton

Profa. Dra. Alessandra de Ávila Montini

- Contatos:
  - E-mail: professor.dinomagri@gmail.com
  - Twitter: https://twitter.com/prof_dinomagri
  - LinkedIn:http://www.linkedin.com/in/dinomagri
  - Site: http://www.dinomagri.com

Currículo

- **(2014-Presente)** – Professor no curso de Extensão, Pós e MBA na Fundação Instituto de Administração (FIA) – www.fia.com.br
- **(2013-Presente)** – Pesquisa e Desenvolvimento no Laboratório de Arquitetura e Redes de Computadores (LARC) na Universidade de São Paulo – www.larc.usp.br
- **(2013)** – Professor no MBA em Desenvolvimento de Inovações Tecnológicas para WEB na IMED Passo Fundo – RS – www.imed.edu.br
- **(2012)** – Bacharel em Ciência da Computação pela Universidade do Estado de Santa Catarina (UDESC) – www.cct.udesc.br
- **(2009/2010)** – Pesquisador e Desenvolvedor no Centro de Computação Gráfica – Guimarães – Portugal – www.ccg.pt
- **Lattes:** http://lattes.cnpq.br/5673884504184733

Material das aulas

- Material das aulas:
  - https://bitly.com/posmba-turma4
  - Senha: fia2017
- Faça o download do arquivo **2017-10-11-py-aula4.zip**
- Salve na Área de Trabalho (Desktop)
- Depois que finalizar o download, acesse a pasta Área de trabalho e descompacte o arquivo `2017-10-11-py-aula4.zip`.

Conteúdo da Aula

- Objetivo
- Introdução
- Twitter REST API
- Exercícios

Conteúdo da Aula

- **Objetivo**
- Introdução
- Twitter REST API
- Exercícios

Objetivo

- Objetivo dessa aula é introduzir os conceitos sobre as **APIs do Twitter** e como utilizá-las.

Conteúdo da Aula

- Objetivo
- **Introdução**
- Twitter REST API
- Exercícios

O que é uma API?

O que é uma API?

- É um **conjunto de padrões** para acesso a uma plataforma baseada na Web.
- É uma interface de comunicação que **possibilita que diferentes tipos de software comuniquem entre si**.
- Uma API deve fornecer:
  - Flexibilidade, Segurança, Simplicidade no Uso, Escalabilidade, Portabilidade.

O que é uma API?

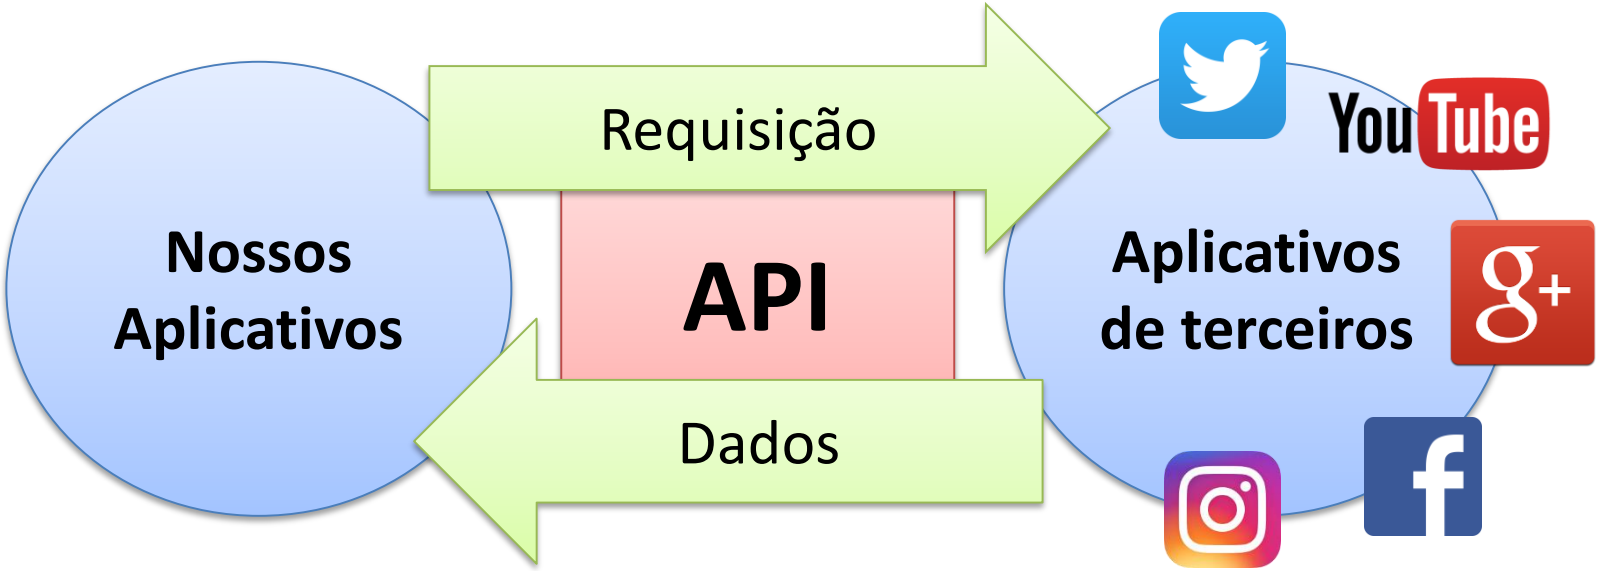

API do Twitter

- Existem diversas APIs para acessar os dados do Twitter:
  - REST API 
  - Streaming API 
  - Ads API
  - Entre outras: https://dev.twitter.com/overview/api

API do Twitter

- **REST API**
  - Permite ler e escrever tweets via API do Twitter, além de recuperar informações sobre o perfil, seguidores, entre outros.
- **Streaming API**
  - Permite ter acesso continuo de novas respostas para as mesmas requisições das consultas realizadas pela REST API através de conexões HTTP.
- Ads API
  - Permite integrar propaganda dos parceiros do Twitter para gerenciar seus produtos.

API do Twitter

- Além disso, iremos utilizar **OAuth** para conectar usuários ao Twitter e enviar requisições seguras e autorizadas para as APIs do Twitter.

- Para acessar as APIs do Twitter precisamos:

Credenciais de acesso da API do Twitter

- Ter uma conta no https://twitter.com
- Ter um número de telefone associado a conta
  - Clique na Foto do perfil → Configurações
  - No menu esquerdo clique em Celular
  - Adicione o número e salve.

Esses passos devem ter sido realizados antes da aula!

- Acessar https://apps.twitter.com para criar uma nova aplicação de acesso

Credenciais de acesso da API do Twitter

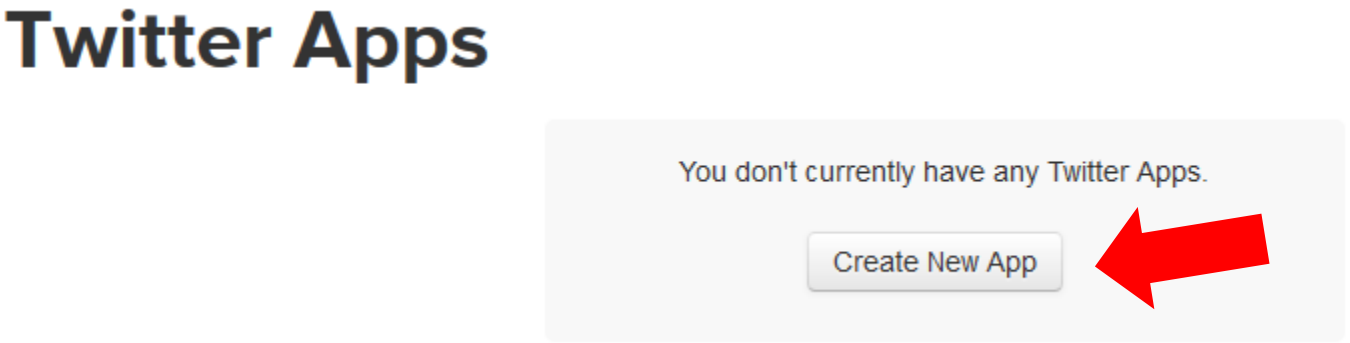

Credenciais de acesso da API do Twitter

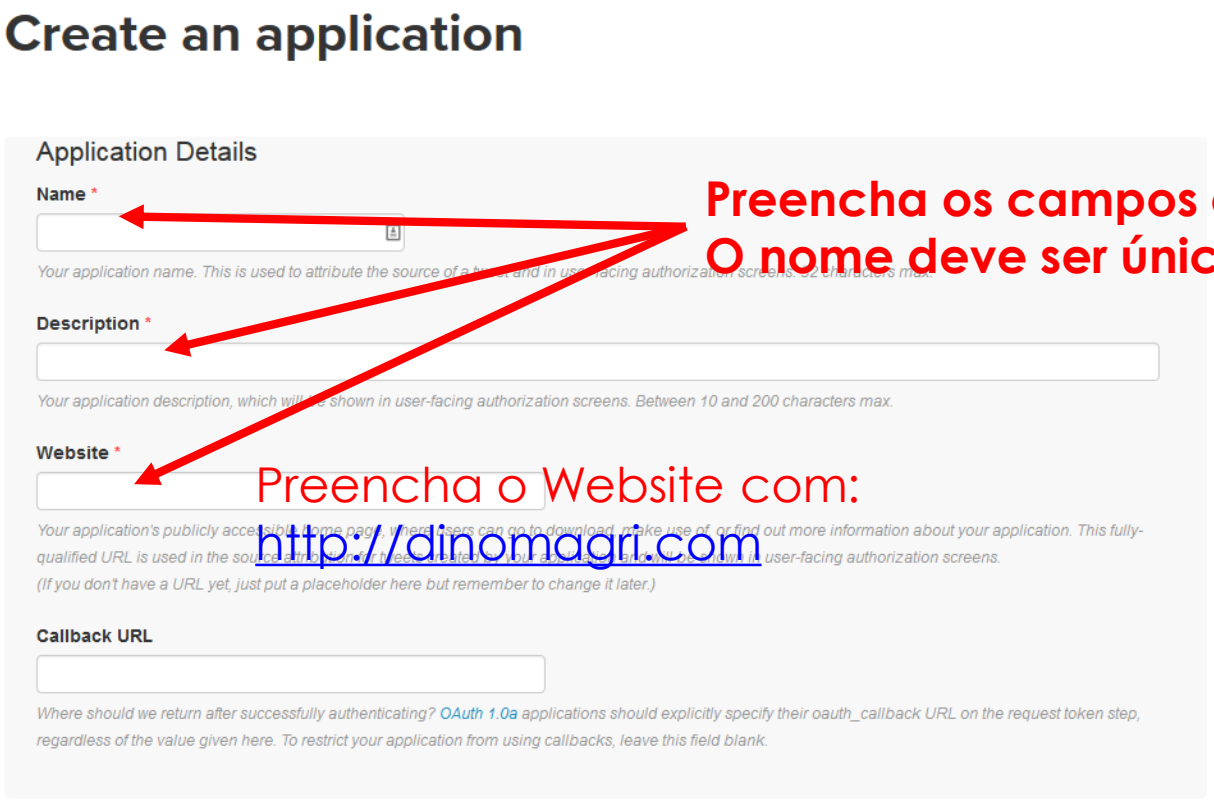

Credenciais de acesso da API do Twitter

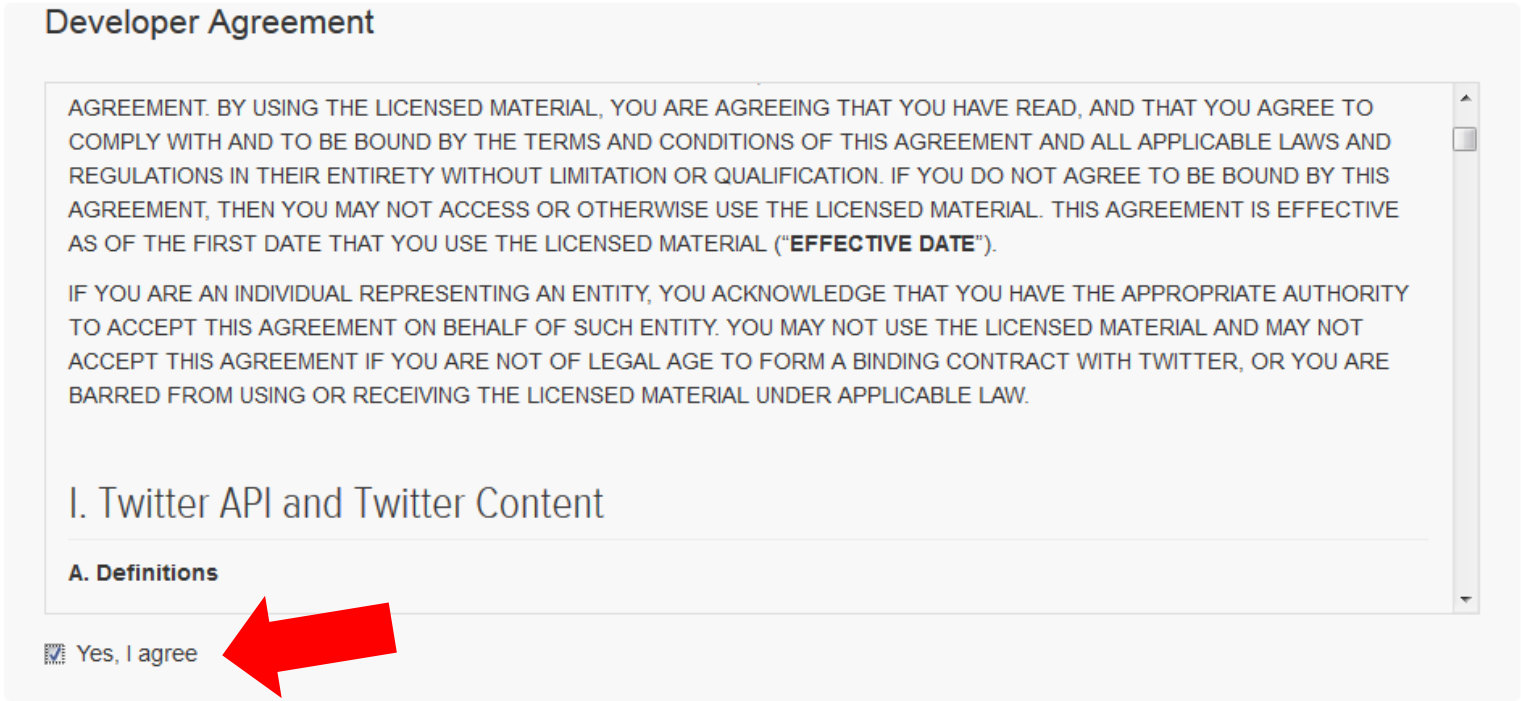

Credenciais de acesso da API do Twitter

Esse erro aconteceu pois o celular não foi adicionado corretamente! Refaça o passo para adicionar o telefone celular!!!

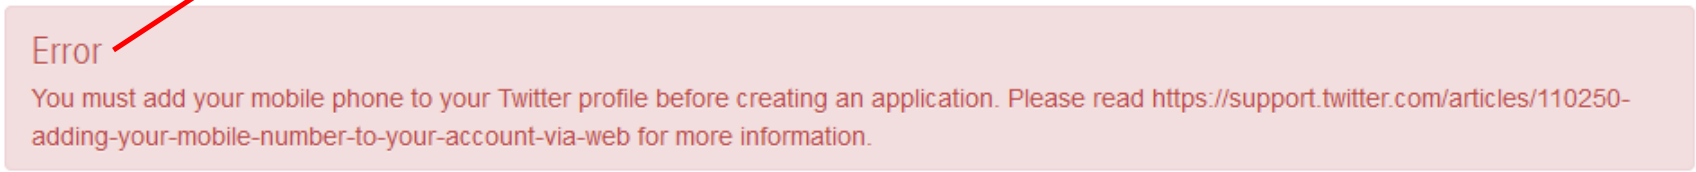

Credenciais de acesso da API do Twitter

Clique na Foto do perfil → Configurações

Adicione o telefone e confirme com o código enviado para o seu celular.

Tente criar novamente a aplicação!

Credenciais de acesso da API do Twitter

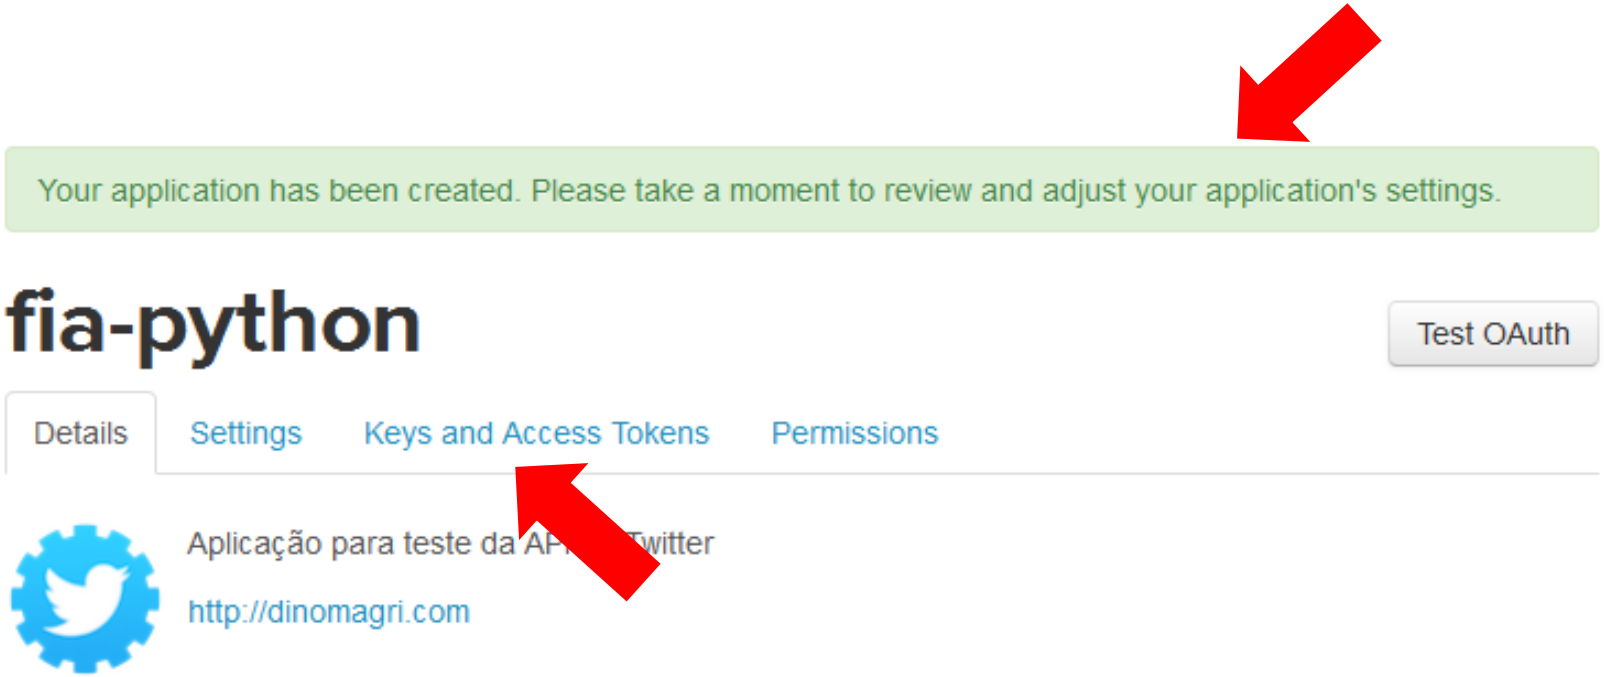

Credenciais de acesso da API do Twitter

fia-python

Test OAuth

Details | Settings | Keys and Access Tokens | Permissions

Application Settings

Keep the "Consumer Secret" a secret. This key should never be hu... dable in your application.

Consumer Key (API Key)	FNUn3AkooMDWZ92mKQZmLCWDO
Consumer Secret (API Secret)	my71XtfSVscBQU1uC4qSoAYGEs9xmEucJirWxdKQqAt5sN8r1t
Access Level	Read and write (modify app permissions)
Owner	prof_dinomagri
Owner ID	3311191877

Credenciais de acesso da API do Twitter

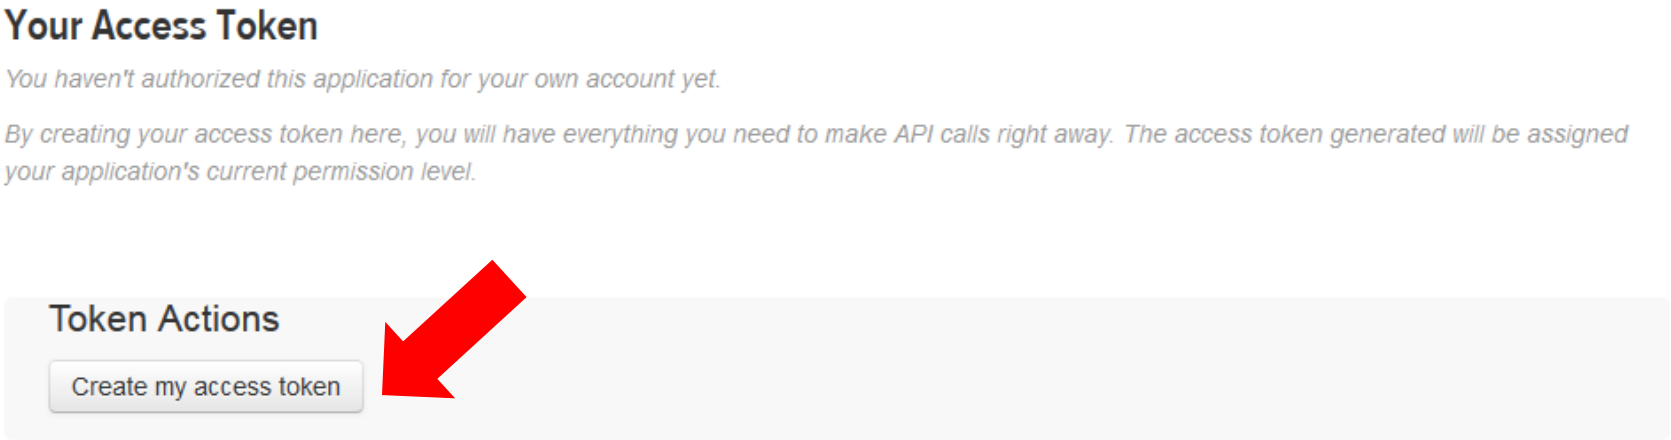

Credenciais de acesso da API do Twitter

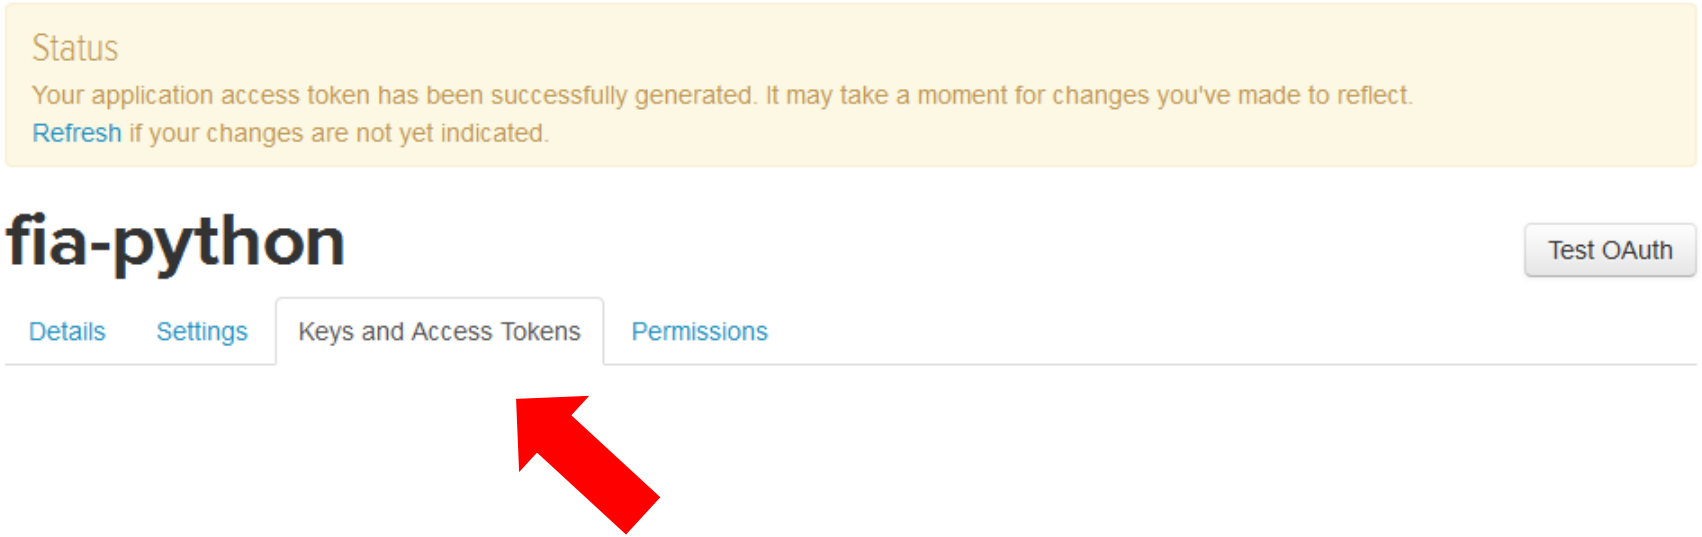

Credenciais de acesso da API do Twitter

Your Access Token

This access token can be used to make API requests on your own account's behalf. Do not share your access token secret with anyone.

Access Token	3311191877-C2mtgsxw3vpCwWpgRv1xLp3Amt5MQkJwRFPHB8Y
Access Token Secret	wg8Vnf16AA1sG6DGDZyllWt91ClmCYUKq54NRUgFVX4Jp
Access Level	Read and write
Owner	prof_dinomagri
Owner ID	3311191877

Credenciais de acesso da API do Twitter

- Para visualizar todas as aplicações criadas, digite: https://apps.twitter.com/
- Se clicar na aplicação, terá acesso as todas as configurações da mesma.

Credenciais de acesso da API do Twitter

- Pronto! Já temos as credenciais de acesso:
  - Consumer Key (API Key)
  - Consumer Secret (API Secret)
  - Access Token
  - Access Token Secret

Módulo Tweepy

- Para acessar a API do Twitter iremos utilizar um módulo do Python chamado Tweepy.

Módulo Tweepy

Tweepy

An easy-to-use Python library for accessing the Twitter API.

- Permite atualizar o status
- Permite receber informações do perfil
- Permite monitorar os tweets e realizar alguma ação quando um evento acontecer.
- Permite receber os tweets públicos.
- Seguir todos os usuários que seguirem o usuário autenticado.
- E muito mais!

http://docs.tweepy.org/en/latest/api.html

Módulo Tweepy

- Para instalar o módulo Tweepy, abra o CMD (terminal para Linux e MacOS X) e digite:
  - `pip install tweepy`
    - `oauthlib` – biblioteca que permite o uso do protocolo de autorização segura.
    - `requests` – permite o uso de envio de requisições HTTP.
    - `requests-oauthlib` – possibilita o suporte da biblioteca OAuth para o requests.
    - `six` – mantém a compatibilidade entre Python 2 e 3.

Módulo Tweepy

- Para testar é só importar o módulo:

```
>>> import tweepy
```

Conteúdo da Aula

- Objetivo
- Introdução
- **Twitter REST API**
- Exercícios

Twitter REST API

- Para utilizar a API do Twitter, temos que garantir que as requisições sejam seguras e autorizadas, para isso iremos utilizar o **OAuth**.

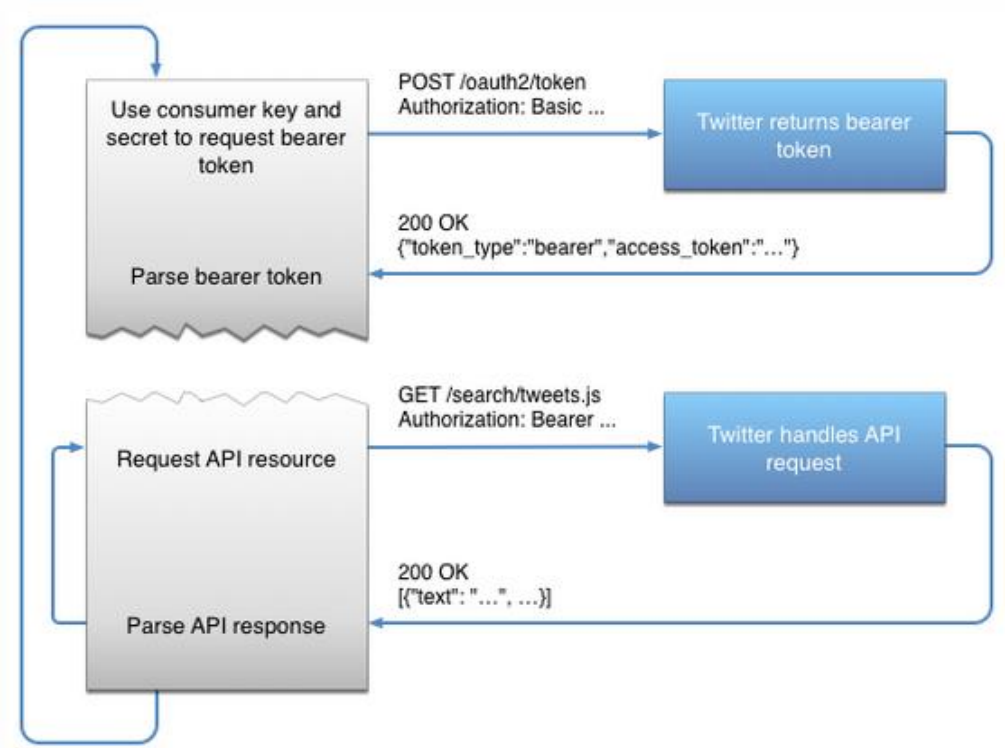

Fonte: https://dev.twitter.com/oauth/application-only

Twitter REST API

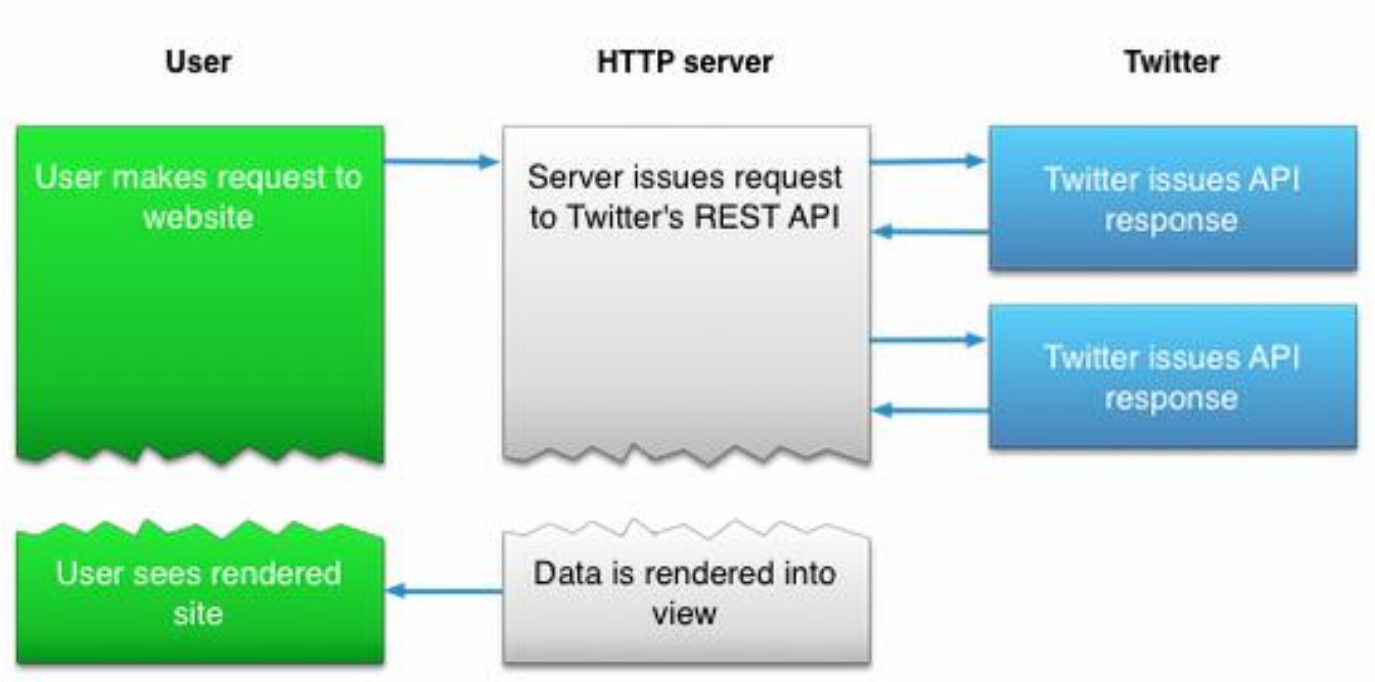

Fonte: https://dev.twitter.com/rest/public

Twitter REST API

- Iremos criar programas para:
  - Publicar um tweet na timeline autenticada
  - Recuperar dados
  - Pesquisar tweets que tenham determinados termos

Algumas considerações

- Limites da API
  - GET: https://dev.twitter.com/rest/public/rate-limits
    - Search: 180 ou 450 chamadas a cada 15 minutos
  - POST: https://support.twitter.com/articles/289867
    - Mensagens diretas: 1000/dia
    - Tweets: 2400/dia
    - Seguir: 1000/dia

Chega de papo! Vamos criar códigos!

Publicar um Tweet

Solicitar para a API

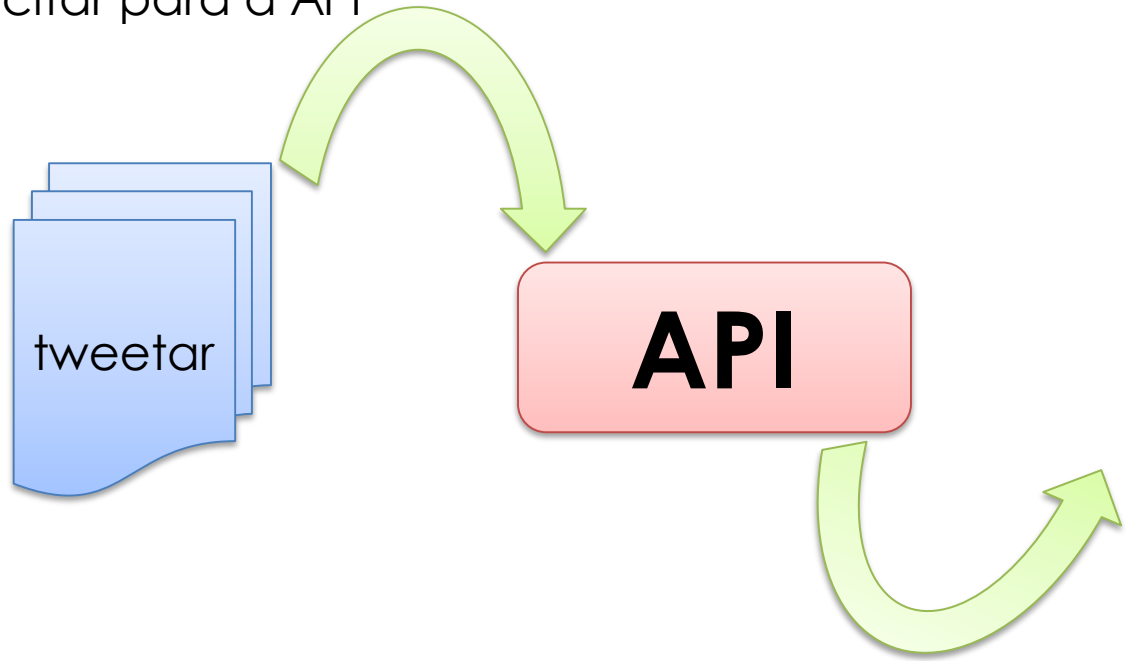

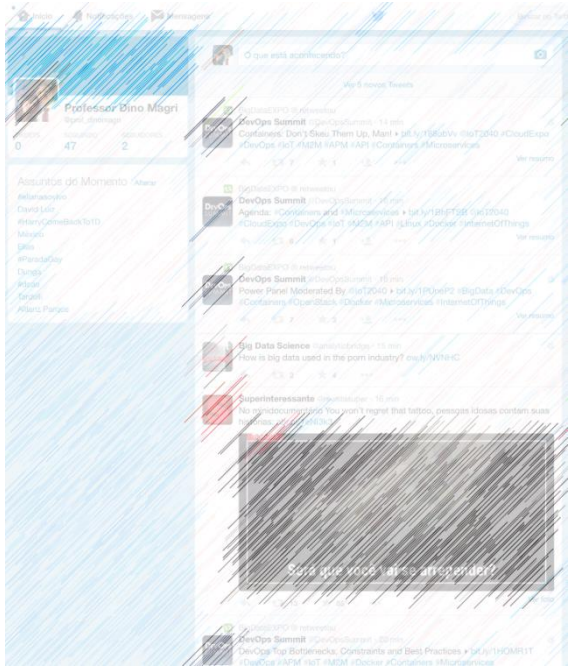

Publicar um tweet na timeline autenticada

Publicar um Tweet

- Primeiro passo do nosso código é importar o módulo tweepy e criar strings que devem conter as chaves e tokens de acesso.

```
import tweepy
consumer_key = ''
consumer_secret = ''
access_token = ''
access_token_secret = ''
```

Publicar um Tweet

- Através da classe **OAuthHandler** do módulo tweepy iremos criar autorização e depois definiremos o acesso.

```
autorizar = tweepy.OAuthHandler(consumer_key,
consumer_secret)


autorizar.set_access_token(access_token,
access_token_secret)
```

Publicar um Tweet

- Atualmente o Twitter não define prazo de validade dos tokens, assim, é necessário reinvocar o direito de acesso da aplicação para finalizar o seu uso.
- Uma vez autorizado, queremos ter acesso aos métodos disponíveis na API.

```
api = tweepy.API(autorizar)
```

- Tuitando ☺

```
api.update_status(status="Big Data")
```

Fonte: https://dev.twitter.com/rest/reference/post/statuses/update

Publicar um Tweet

- O retorno será:

```
Status(in_reply_to_status_id=None, favorite_count=0, truncated=False,
id_str='758354516060299264', contributors=None,
in_reply_to_screen_name=None, lang='pt', created_at=datetime.datetime(2016,
7, 27, 17, 33), in_reply_to_user_id=None, source='fia-python',
author=User(geo_enabled=True, friends_count=53,
screen_name='prof_dinomagri', id=3311191877,
profile_use_background_image=True, verified=False,
created_at=datetime.datetime(2015, 6, 6, 22, 16, 52), is_translator=False,
profile_background_image_url='http://abs.twimg.com/images/themes/theme1/bg.p
ng', ... continua ...
```

Publicar um Tweet

- Quando invocamos um método da API (e.g. `update_status`), o Twitter **realiza** a ação e **retorna** a resposta em formato JSON.
- O Tweepy por sua vez realiza a instancia da classe **Models**.
- Desta forma, poderemos acessar os dados que foram retornados e utilizar dentro de nossa aplicação. Por exemplo:

```
>>> retorno = api.update_status(status="O que é big data?")
>>> print(type(retorno))
<class 'tweepy.models.Status'>
```

Publicar um Tweet

```
>>> print(dir(retorno))
['author', 'contributors', 'coordinates', 'created_at', 'destroy',
'entities', 'favorite', 'favorite_count', 'favorited', 'geo', 'id',
'id_str', 'in_reply_to_screen_name', 'in_reply_to_status_id',
'in_reply_to_status_id_str', 'in_reply_to_user_id',
'in_reply_to_user_id_str', 'is_quote_status', 'lang', 'parse', 'parse_list',
'place', 'retweet', 'retweet_count', 'retweeted', 'retweets', 'source',
'source_url', 'text', 'truncated', 'user']

>>> print(retorno.id)

758361343275704320

>>> api.destroy_status(id=retorno.id)

Status(in_reply_to_status_id=None, favorite_count=0, truncated=False,

id_str='758361343275704320' ... continua ...
```

Publicar um Tweet

- Abra o arquivo aula4-parte1-atualizando-status.ipynb para visualizar outros exemplos.

Recuperar Tweets

Solicitar para a API os *tweets* públicos da *timeline*

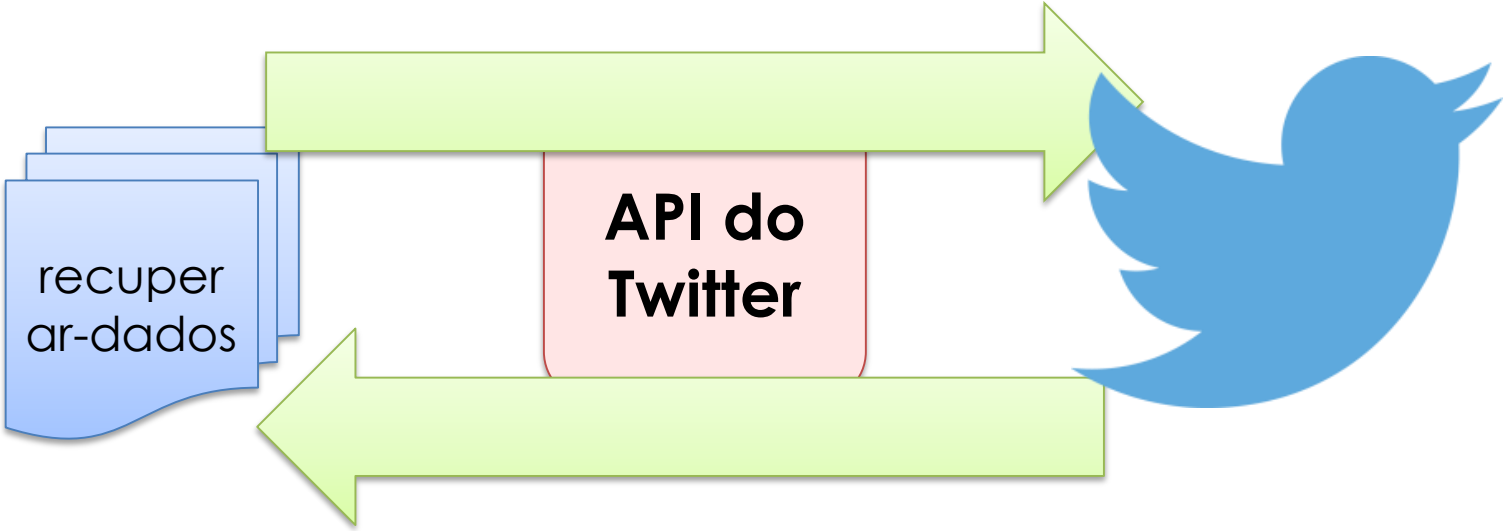

Twitter irá devolver os dados solicitados

Recuperar Tweets

- Para criar esse programa, temos que:
  - Importar o módulo
  - Definir as chaves e tokens de acesso
  - Criar a autorização
  - Definir o acesso
  - Criar a API com base no acesso

Recuperar Tweets

```
import tweepy

consumer_key = ''

consumer_secret = ''

access_token = ''

access_token_secret = ''

autorizar = tweepy.OAuthHandler(consumer_key, consumer_secret)

autorizar.set_access_token(access_token, access_token_secret)

api = tweepy.api(autorizar)
```

Recuperar Tweets

- Vamos utilizar a `home_timeline()` para recuperar as últimas 20 atualizações, incluindo retweets, da timeline do usuário autenticado.
- Vamos utilizar a `user_timeline()` para recuperar as 5 atualizações de um usuário específico.
- Vamos utilizar a `retweets_of_me()` para recuperar os retweets que foram feitos dos meus posts.

Recuperar Tweets

- Abra o arquivo aula4-parte2-recuperar-tweets.ipynb para visualizar o código e outros exemplos.

Pesquisar por Tweets

Solicitar para a API pesquisar por *tweets* públicos que combinam com um termino definido

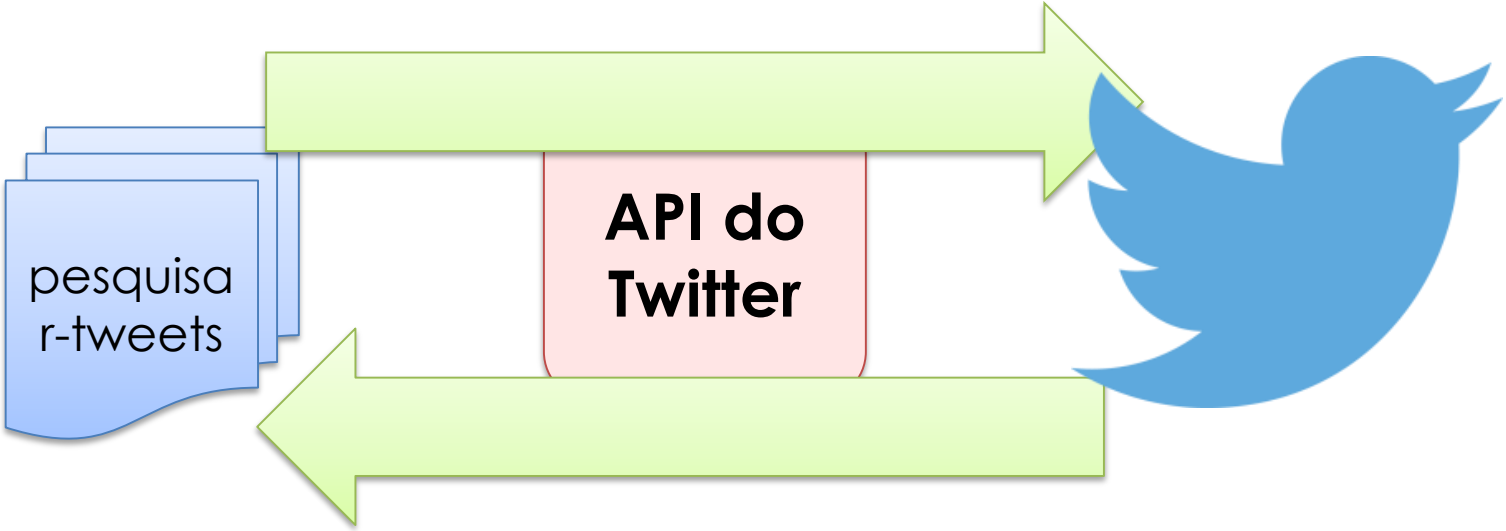

Twitter irá devolver os dados solicitados

Pesquisar por Tweets

- Na API REST podemos utilizar o método **`search`** para procurar por tweets que combinam com o termo definido.
- O método contém algumas opções como:

```
api.search(q, count, max_id, lang)
```

  - **`q`** é o parâmetro que terá o termo a ser pesquisado.
  - **`count`** é a quantidade de tweets que serão retornados. O limite é 100 e o padrão é 15.
  - **`max_id`** retorna apenas os tweets com o ID menor ou igual ao que foi especificado.
  - **`lang`** restringe a busca por tweets de um determinado idioma.

Pesquisar por Tweets

- Para criar esse programa, temos que realizar os mesmos passos iniciais que fizemos nos programas anteriores.
  - Importar o módulo, definir as chaves e tokens de acesso, criar a autorização, definir o acesso e criar a API.

Pesquisar por Tweets

- Por padrão, o método `search` permite retornar apenas os 100 primeiros tweets.
- Mesmo que o parâmetro `count` seja definido, por exemplo, `count=1000`.
- Para recuperar 1000 tweets, precisamos criar algumas estruturas de controle para que seja possível salvar esses tweets.

Pesquisar por Tweets

Como podemos fazer isso?

Pesquisar por Tweets

- Primeiro, vamos criar uma lista para salvar os tweets, definir uma variável para pegar o último id que foi recuperado e outra para a quantidade de tweets que queremos buscar.

```
tweets_salvos = []

ultimo_id = -1

qtde_tweets = 1000
```

Pesquisar por Tweets

- Agora precisamos criar um laço de repetição que irá repetir enquanto não recuperarmos os 1000 elementos que serão salvos na lista `tweets_salvos`.

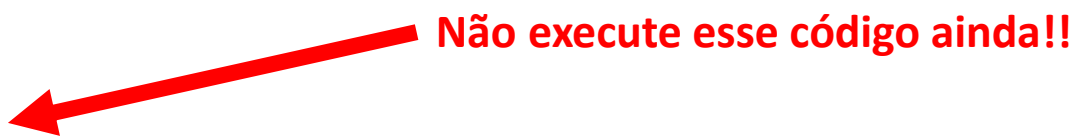


```
while len(tweets_salvos) < qtde_tweets:

    contador = qtde_tweets - len(tweets_salvos)
```

Pesquisar por Tweets

- Como estamos trabalhando com a API do Twitter e iremos criar um laço até preencher os 1000 elementos, temos que **cuidar de possíveis erros**. Por exemplo:
  - Pode acontecer da internet cair e a conexão com o Twitter seja finalizada.
  - Pode acontecer de não existir os 1000 elementos.
  - Pode acontecer do Twitter impor algum limite de uso.
  - Entre outras situações.
- Python facilita bastante a forma para tratamento de exceções.

Abra o arquivo "aula4-parte3-tratamento-excecoes.ipynb"

Pesquisar por Tweets

- Agora que sabemos como tratar erros em nosso código, podemos tentar **recuperar os tweets e caso aconteça algum erro**, **iremos imprimir** e **finalizar o laço de repetição**.
- O método `api.search` tem o parâmetro `max_id`, que permite recuperar os tweets anteriores ao valor definido no `max_id`.
- Com isso, podemos recuperar os tweets do último até o 100º, do 101º até 200º, 201º até 300º e assim sucessivamente.

Pesquisar por Tweets

- Com o par **`try/except`**, vamos utilizar a `api.search` passando a palavra (`q`) que queremos buscar, o contador (`count`) e vamos definir o `max_id` para recuperar os tweets anteriores ao último id recuperado.

```
        try:
                novos_tweets = api.search(q='Python',
count=contador, max_id=str(ultimo_id - 1))
        except tweepy.TweepError as e:
                print("Erro:", (e))
                break
```

Pesquisar por Tweets

- Se nenhum tweet for recuperado, temos que finalizar o laço. Podemos fazer uma verificação na lista `novos_tweets`, **se estiver vazia iremos finalizar o laço** (`break`).
- Caso contrário, iremos estender a lista tweets_salvos com os dados da lista novos_tweets, utilizando o método extend.
- Também **precisamos atualizar** o `ultimo_id` para que no próximo laço retorne os 100 anteriores ao `ultimo_id`.

Pesquisar por Tweets

```
        try:
                novos_tweets = api.search(q='Python',
count=contador, max_id=str(ultimo_id - 1))
                if not novos_tweets:
                        print("Nenhum tweet para recuperar")
                        break
                tweets_salvos.extend(novos_tweets)
                ultimo_id = novos_tweets[-1].id
        except tweepy.TweepError as e:
                print("Erro:", (e))
                break
```

Pesquisar por Tweets

- Com isso, podemos lidar com possíveis erros e também salvar os 1000 tweets que queremos.
- Por fim, vamos imprimir todos os tweets.

```
for i, tweet in enumerate(tweets_salvos, start=1):
    print("{} ---- {}".format(i, tweet.text))
```

```
tweets_salvos = []
ultimo_id = -1
qtde_tweets = 1000
while len(tweets_salvos) < qtde_tweets:
          contador = qtde_tweets - len(tweets_salvos)
          try:
                    novos_tweets = api.search(q='Python', count=contador,
max_id=str(ultimo_id - 1))
                    if not novos_tweets:
                              print("Nenhum tweet para recuperar")
                              break
                    tweets_salvos.extend(novos_tweets)
                    ultimo_id = novos_tweets[-1].id
          except tweepy.TweepError as e:
                    print("Erro:", (e))
                    break
for i, tweet in enumerate(tweets_salvos, start=1):
    print("{} ---- {}".format(i, tweet.text))
```

Código completo no notebook - "aula4-parte4-pesquisar-tweets.ipynb"

Conteúdo da Aula

- Objetivo
- Introdução
- Twitter REST API
- **Exercícios**

Exercícios

- **Exercício 1** – Utilizando o método `update_with_media`, realize a atualização do status utilizando a imagem fia.jpg disponível na pasta da aula.

  - Além da imagem, adicione a mensagem: `"Programação com Python e Twitter na FIA!"`

  - Lembre-se de utilizar a função `help(api.update_with_media)` para ver os nomes dos parâmetros necessários.

Exercícios

- **Exercício 2** - Salve o retorno do tweet do exercício anterior e imprima as seguintes informações:
  - **tweet**

    `id, created_at, lang, text`
  - **user**

    `screen_name, friends_count, time_zone`

Por fim, remova o tweet, utilizando o método `destroy_status`.

Exercícios

- **Exercício 3** - Utilizando o método `home_timeline()`, recupere os 10 tweets atuais. Para cada um desses tweets, imprima:
  - o screen_name
  - o texto do tweet
  - o id do usuário

Exercícios

- **Exercício 4** - Para cada tweet do exercício anterior, utilize o id do usuário e recupere os 5 primeiros tweets de cada um dos 10 usuários (`user_timeline`).

Referências Bibliográficas

- **21 Recipes for Mining Twitter** – Matthew A. Russell – USA: O'Reilly, 2011.

- **Mastering pandas** – Femi Anthony – Packt Publishing, 2015.

- **Python for Data Analysis** – Wes McKinney – USA: O'Reilly, 2013.

- Referência da API do Tweepy - http://docs.tweepy.org/en/latest/api.html

Referências Bibliográficas

- **Python for kids – A playful Introduction to programming** – Jason R. Briggs – San Francisco – CA: No Starch Press, 2013.

- **Python Cookbook** – David Beazley & Brian K. Jones – O'Reilly, 3th Edition, 2013.

- As referências de links utilizados podem ser visualizados em http://urls.dinomagri.com/refs